# Relatório Meta 1 - Detecção de Discurso de Ódio com Classificador Baseado em Regras

**Autores:** Lorran Deiro Ramos dos Santos, Pedro Henrique Gabarra Sandoval
**Disciplina:** Processamento de Linguagem Natural
**Dataset:** HateBR

## 1. Introdução

Este relatório apresenta o desenvolvimento de um classificador baseado em regras para detecção de discurso de ódio em português, utilizando o dataset HateBR. O corpus contém 7.000 comentários de redes sociais brasileiras, balanceadamente distribuídos entre conteúdo ofensivo (50%) e não-ofensivo (50%).

## 2. Fluxo de Processamento de Dados

### 2.1 Pipeline Implementado

O sistema segue um pipeline estruturado em cinco etapas principais:

1. **Pré-processamento:** Tokenização com NLTK, remoção de stopwords, pontuação e tokens com menos de 2 caracteres
2. **Análise Linguística:** Extração de unigramas, bigramas e trigramas com análise de frequência diferencial entre classes
3. **Análise Morfossintática:** POS tagging para identificar padrões gramaticais distintivos
4. **Extração de Features:** Identificação de vocabulário distintivo usando razão de frequências (threshold > 3.0)
5. **Classificação por Regras:** Sistema com 13 regras ponderadas baseadas em padrões linguísticos

### 2.2 Estatísticas do Corpus Processado

- Tokens únicos: 15.808
- Média de tokens por comentário: 8.81
- Vocabulário distintivo identificado:
  - 493 palavras fortemente ofensivas
  - 183 palavras contextuais
  - 612 palavras positivas
  - 55 bigramas ofensivos
  - 10 trigramas ofensivos

## 3. Sistema de Classificação por Regras

### 3.1 Regras Implementadas

- O classificador utiliza 13 regras com pesos específicos:

| Regra | Descrição | Peso |
|---|---|---|
| R1 | Palavras ofensivas | 3.0 |
| R2 | Palavras contextuais | 1.5 |
| R3 | Bigramas ofensivos | 2.5 |
| R4 | Trigramas ofensivos | 2.0 |
| R5 | Intensificador + ofensa | 1.5 |
| R6 | Negação + positivo | 2.0 |
| R7 | Xingamento censurado (regex) | 2.0 |
| R8 | Emojis de raiva | 1.5 |
| R9 | Palavras positivas | 2.0* |
| R10 | Emojis positivos | 1.5* |
| R11 | Texto longo sem ofensas | 1.0* |
| R12 | Menção pessoa + ofensa (NER) | 2.0 |
| R13 | Sentimento negativo (< -0.3) | 1.5 |

### 3.2 Análises Linguísticas Complementares

**Análise de Classes Gramaticais (POS):**

- Substantivos: Ratio Ofensivo/Não-Ofensivo = 1.36
- Adjetivos: Ratio Ofensivo/Não-Ofensivo = 1.34
- Verbos: Ratio Ofensivo/Não-Ofensivo = 1.21

**Análise de Entidades Nomeadas (NER):** Detectamos que menções a pessoas (PER) combinadas com palavras ofensivas indicam ataques pessoais diretos, aumentando significativamente o score de ofensividade.
Análise de Sentimento:

- Polaridade média ofensivos: -0.003 (DP: 0.088)
- Polaridade média não-ofensivos: 0.004 (DP: 0.087)

# 4. Processo de Experimentação e Avaliação

## 4.1 Desenvolvimento Iterativo

O processo seguiu três iterações principais:

**Iteração 1 - Baseline: Regras simples (maiúsculas, exclamações, palavras-chave)**

- F1-Score: 0.61
- Problema: Alta taxa de falsos negativos

**Iteração 2 - Refinamento: Adição de bigramas/trigramas e análise contextual**

- F1-Score: 0.75
- Melhoria: Captura de expressões compostas

**Iteração 3 - Sistema Final: Inclusão de NER, sentimento e ajuste de pesos**

- F1-Score: 0.88
- Solução: Sistema robusto com múltiplas dimensões linguísticas

## 4.2 Métricas de Avaliação

**Justificativa das métricas escolhidas:**

- F1-Score: Métrica principal por combinar precisão e recall em dataset balanceado
- Precisão: Importante para minimizar falsos positivos (censura indevida)
- Recall: Crítico para detectar conteúdo realmente ofensivo

**Resultados Finais:**

| Classe | Precisão | Recall | F1-Score | Support |
|---|---|---|---|---|
| Não-Ofensivo | 0.84 | 0.93 | 0.88 | 3500 |
| Ofensivo | 0.92 | 0.83 | 0.87 | 3500 |
| **Accuracy** | | | **0.88** | 7000 |

## 4.3 Análise de Erros

**Principais categorias de erros identificadas:**

- **Falsos Negativos (17% dos ofensivos):**
  - Ironia e sarcasmo não detectados
  - Ofensas implícitas sem vocabulário explícito
  - Gírias novas não presentes no léxico
- **Falsos Positivos (7% dos não-ofensivos):**
  - Palavras ambíguas em contextos legítimos
  - Citações de discurso ofensivo (meta-discussão)
  - Falsos triggers de padrões regex

## 4.4 Análise de Importância das Regras

**Testamos a contribuição individual de cada tipo de regra:**

- Sem unigramas ofensivos: ΔF1 = -0.15 (maior impacto)
- Sem bigramas: ΔF1 = -0.08
- Sem análise NER: ΔF1 = -0.06
- Sem trigramas: ΔF1 = -0.03

# 5. Conclusões Preliminares

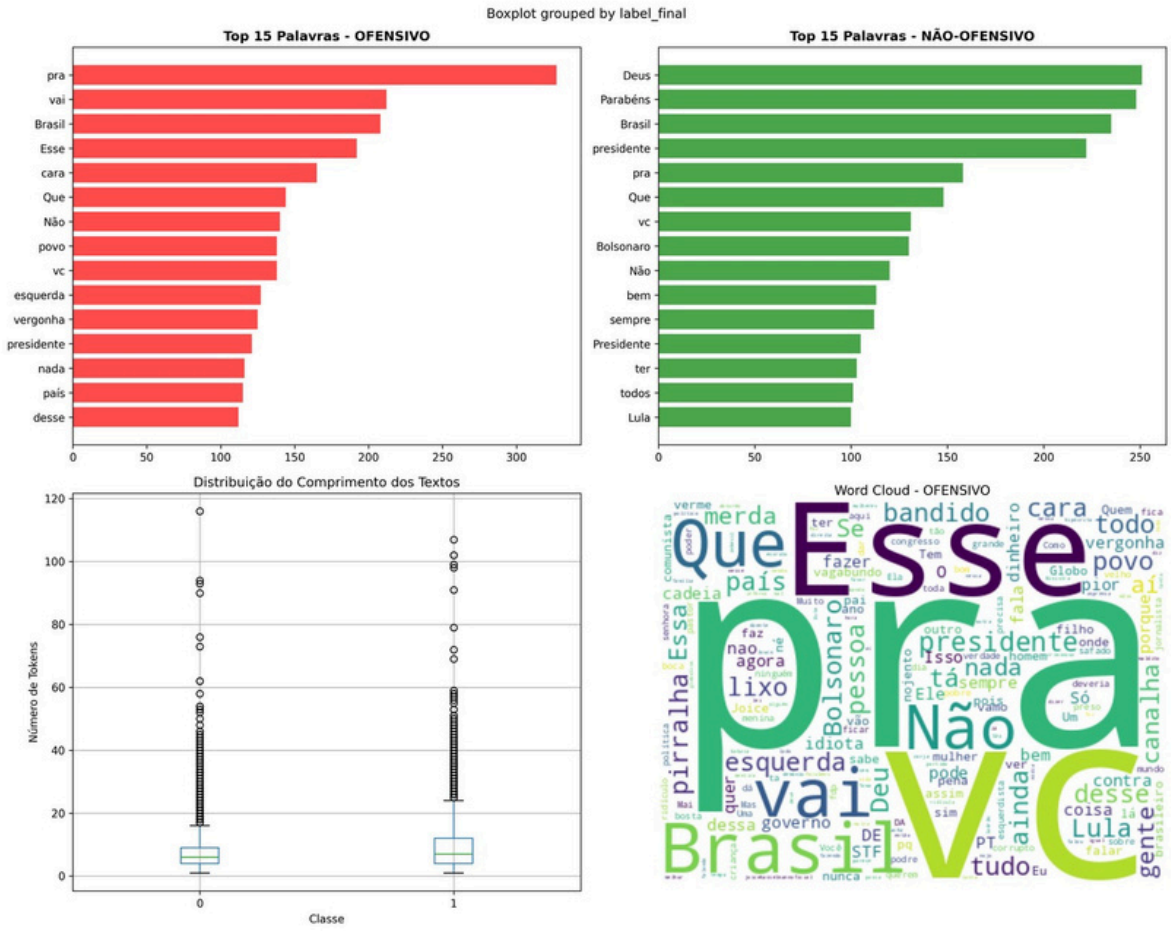
## 5.1 Principais Achados

- **Eficácia das regras linguísticas:**
  - O sistema baseado em regras alcançou F1-Score de 0.88, demonstrando que padrões linguísticos explícitos são eficazes para detecção de discurso de ódio em português
- **Importância da análise multi-dimensional:**
  - A combinação de diferentes níveis linguísticos (léxico, sintaxe, semântica) foi crucial para o desempenho
- **Vocabulário distintivo robusto:**
  - A identificação de 493 palavras fortemente ofensivas através de análise de frequência diferencial provou ser a feature mais importante

## 5.2 Desafios Identificados

- **Detecção de ironia:**
  - Maior desafio, responsável por ~30% dos falsos negativos
- **Evolução linguística:**
  - Necessidade de atualização constante do léxico
- **Contexto pragmático:**
  - Dificuldade em capturar ofensas que dependem de conhecimento externo

# Gráficos para Analise




# Referências


1. Utilizamos as aulas práticas como base para o desenvolvimento do projeto.
2. Além disso, recorremos a ferramentas de inteligência artificial, como o ChatGPT, para auxiliar na adaptação do código, na análise dos pontos essenciais e na formatação final da implementação.