Relatório de Análise: Detecção de Discurso de Ódio (HateBR)

Autores: Lorran Deiró Ramos dos Santos e Pedro Henrique Gabarra Sandoval
Cadeira: Processamento de Linguagem Natural
Dataset: HateBr

Este relatório analisa o desempenho de quatro modelos de Aprendizado de Máquina (Naive Bayes, SVM, Regressão Logística e CNN) e compara seus resultados entre si e com um Classificador Baseado em Regras desenvolvido anteriormente. O *dataset* utilizado (HateBR) está balanceado, contendo 7.000 comentários divididos igualmente entre ofensivos e não-ofensivos (50% cada).

---

1. Naive Bayes (Naive Bayes Multinomial)

Como funciona?
O Naive Bayes é um classificador probabilístico que se baseia no Teorema de Bayes. Ele é chamado de "Naive" (ingênuo) porque assume que todas as features (neste caso, as palavras no texto, representadas pelo TF-IDF) são independentes entre si, o que raramente é verdade na realidade da linguagem, mas mesmo assim funciona surpreendentemente bem em muitos casos. Para classificação de texto, o Naive Bayes Multinomial calcula a probabilidade de um texto pertencer a uma classe baseando-se na frequência das palavras, funcionando como um contador de evidências.

Por que escolhemos este modelo?

- **Baseline de Referência:** É considerado o padrão-ouro (*baseline*) para tarefas de classificação de texto; qualquer modelo complexo deve superá-lo para justificar seu custo computacional.
- **Eficiência com Alta Dimensão:** Lida excepcionalmente bem com vetores esparsos (como o TF-IDF com 5000 features), onde a maioria das palavras não aparece em todos os textos.
- **Natureza da Tarefa:** Discurso de ódio explícito frequentemente depende da presença de palavras-chave específicas (ex: palavrões), cenário onde a abordagem probabilística de contagem de palavras do Naive Bayes se destaca.

Análise dos Resultados:

- **Desempenho Geral:** O modelo apresentou um desempenho sólido, sendo o melhor entre os algoritmos clássicos (excluindo a CNN).
    - **Acurácia:** 84.86%

    - **F1-Score:** 0.8504
- **Matriz de Confusão:** O modelo equilibrou bem os erros, com ligeira tendência a identificar melhor a classe ofensiva (Recall de 0.86).
- **Features Discriminativas:** Os coeficientes mostram que o modelo aprendeu corretamente palavras indicadoras de ofensa ("pra", "esse", "lixo", "merda") e de não-ofensa ("parabéns", "Deus", "Brasil").

---

2. SVM (Support Vector Machine - Máquina de Vetores de Suporte)

Como funciona?
O SVM busca encontrar o "hiperplano" (uma linha em 2D, um plano em 3D, etc.) que melhor separa as diferentes classes dos dados. O objetivo é maximizar a margem entre o hiperplano e os pontos de dados mais próximos de cada classe (os "vetores de suporte"). No contexto de texto com TF-IDF, o SVM opera em um espaço de alta dimensão para traçar uma fronteira que divide comentários ofensivos de não-ofensivos.

Por que escolhemos este modelo?

- **Robustez em Alta Dimensão:** O SVM é conhecido por não sofrer tanto com a "maldição da dimensionalidade", sendo ideal para vocabulários extensos de texto.
- **Maximização de Margem:** Ao tentar encontrar a maior separação possível entre as classes, o SVM tende a generalizar melhor do que modelos que apenas tentam minimizar o erro nos dados de treino.
- **Eficácia com Dados Esparsos:** O Kernel Linear é historicamente um dos melhores métodos para classificação de texto, pois dados textuais tendem a ser linearmente separáveis em altas dimensões.

Análise dos Resultados:

- **Desempenho Geral:** Ligeiramente inferior ao Naive Bayes em métricas globais, mas com maior precisão.
    - **Acurácia:** 84.11%
    - **F1-Score:** 0.8389
- **Precisão vs Recall:** O SVM priorizou a precisão (0.85) em detrimento do recall (0.82), o que significa que ele erra menos quando afirma que algo é ofensivo, mas deixa passar mais ofensas do que o Naive Bayes.
- **Confiança:** A análise de erros mostra que o SVM tem alta confiança nas predições corretas, mas baixa confiança nos erros, sugerindo que as falhas ocorrem próximas à fronteira de decisão.

---

3. Regressão Logística

Como funciona?
Apesar do nome "Regressão", é um modelo de classificação. Ela usa uma função logística (ou sigmoide) para modelar a probabilidade de um dado ponto pertencer a uma determinada classe (valor entre 0 e 1). Ela aprende os pesos para cada feature (palavra) que melhor predizem a probabilidade de um texto ser ofensivo. Pesos positivos aumentam a probabilidade de ser ofensivo; negativos, o contrário.

Por que escolhemos este modelo?

- **Interpretabilidade:** Permite inspecionar diretamente os coeficientes (pesos) para entender *quanto* cada palavra contribui positiva ou negativamente para a classificação.
- **Saída Probabilística:** Diferente do SVM (que dá uma pontuação de distância), a Regressão Logística fornece uma probabilidade calibrada (ex: "80% de chance de ser ofensivo"), útil para definir limiares de confiança.
- **Simplicidade e Rapidez:** É um modelo linear discriminativo simples, servindo como um contraponto comparativo ao modelo generativo (Naive Bayes).

Análise dos Resultados:

- **Desempenho Geral:** Apresentou o menor desempenho entre os quatro modelos, indicando que a fronteira linear simples baseada em probabilidades pode não ser suficiente para a complexidade deste corpus.
  - **Acurácia:** 83.26%
  - **F1-Score:** 0.8317
- **Incerteza:** A análise de probabilidade mostra que o modelo tem alta confiança (probabilidade > 0.7 ou < 0.3) em apenas 47.8% dos casos, indicando que muitos textos caem em uma "zona cinzenta" para este classificador.

---

4. Redes Neurais Convolucionais (CNN) para Texto

Como funcionam?
Embora conhecidas por visão computacional, as CNNs aplicadas a texto usam "filtros" que deslizam sobre a sequência de palavras (representadas como vetores/embeddings) para identificar padrões locais. Elas capturam a relação entre palavras vizinhas (n-gramas) independentemente de onde apareçam no texto.

Por que escolhemos este modelo?

- **Contexto Local:** Diferente dos modelos anteriores (BoW/TF-IDF) que ignoram a ordem das palavras, a CNN consegue capturar estruturas locais, como a negação ("não gosto") ou expressões idiomáticas ofensivas.

- **Aprendizado de Representações:** Utiliza uma camada de *Embedding* que aprende o significado semântico das palavras, em vez de apenas contar sua frequência.
- **Detecção de Padrões:** Seus filtros funcionam como detectores de características específicas (ex: um filtro pode se especializar em detectar insultos raciais, outro em ameaças políticas), tornando-a robusta para variações no texto.

Análise dos Resultados:

- **Desempenho Geral:** A CNN foi o modelo com o **melhor desempenho geral** entre os métodos de Aprendizado de Máquina.
  - **Acurácia:** 87.94%
  - **F1-Score:** 0.8774
- **Overfitting:** Houve um sinal claro de overfitting (acurácia de treino de 99.9% vs validação de 87.9%) sugerindo que o modelo memorizou o treino, mas ainda assim generalizou melhor que os modelos clássicos.
- **Robustez:** Dominou tanto em Precisão (0.89) quanto em Recall (0.86), provando ser capaz de capturar ofensas que escaparam aos modelos lineares.

---

5. Comparação Final: Métodos de ML vs. Regras e Conclusão

Esta análise culmina na comparação entre a "inteligência artificial" dos modelos de ML e o **Classificador Baseado em Regras** implementado nas etapas iniciais.

Tabela de Confronto (Melhor ML vs. Regras):

Métrica	CNN (Melhor ML)	Classificador Baseado em Regras
Acurácia	**87.94%**	87.91%
F1-Score	**0.8774**	0.8727
Precisão	0.8924	**0.9221**
Recall	**0.8629**	0.8283

Conclusão da Análise

1. **Empate Técnico na Acurácia:** O Classificador Baseado em Regras teve um desempenho técnico praticamente idêntico ao da CNN (diferença de 0.03%), demonstrando que um conhecimento linguístico bem estruturado compete com Deep Learning neste dataset.

2. **Precisão das Regras:** O sistema de regras obteve a **maior precisão do projeto (92.2%)**. Isso indica que quando o sistema aponta uma ofensa baseada em seu léxico e padrões, ele raramente erra.
3. **Recall da CNN:** A CNN venceu no **Recall (86.2% vs 82.8%)**. O sistema de regras falha em ofensas implícitas ou ironias que não possuem palavras-chave cadastradas. A CNN, através dos embeddings e filtros, detectou esses padrões sutis.
4. **Natureza do Corpus:** O alto desempenho do Naive Bayes e das Regras sugere que o *HateBR* contém muito discurso de ódio **explícito** (palavras como "lixo", "merda", "pirralha" são muito discriminativas).

Veredito: A **CNN** é o modelo mais robusto pelo equilíbrio entre precisão e recall. Contudo, o **Sistema de Regras** provou ser extremamente confiável para evitar falsos positivos, sugerindo que uma abordagem híbrida seria a solução ideal.